

Proyecto Final: Reporte técnico

Repositorio

<https://github.com/AmedIman/rag-app>

Corpus y dominio

El proyecto implementa una aplicación de Generación Aumentada por Recuperación (RAG) enfocada en fundamentos de Inteligencia Artificial. El corpus está formado por siete materiales de MIT OpenCourseWare del curso 6.034, que abarcan fundamentos de IA, búsqueda, problemas de satisfacción de restricciones, juegos, aprendizaje automático, lógica y comprensión del lenguaje natural. El corpus contiene 399 páginas y, después de la extracción de texto y segmentación, produce 519 chunks indexados.

Arquitectura RAG

La aplicación utiliza una arquitectura de dos capas. Una interfaz desarrollada con Streamlit se comunica mediante HTTP/JSON con un backend desarrollado con FastAPI. El backend gestiona la ingestión de documentos, la recuperación semántica y la generación de respuestas.

Durante la ingestión, los PDF se procesan mediante PyPDF, se dividen en chunks, se generan embeddings con gemini-embedding-001 y se almacenan de forma persistente en ChromaDB. Para una consulta, la misma técnica convierte la pregunta en un vector; ChromaDB recupera los chunks más relevantes y el contexto recuperado se envía a gemini-3.6-flash, que genera una respuesta en español basada únicamente en la evidencia recuperada.

Estrategia de chunking

El texto extraído de los PDF se divide mediante una ventana deslizante basada en palabras. La configuración utilizada es: 300 palabras por chunk y 60 palabras de solapamiento. Esta superposición permite conservar contexto entre segmentos consecutivos y disminuir la pérdida de información en los límites de los chunks. Cada chunk conserva metadatos de archivo fuente, número de página e identificador único.

Estrategia de abstención

El sistema incorpora un mecanismo de abstención para evitar generar respuestas cuando la evidencia recuperada es insuficiente. ChromaDB devuelve una distancia para cada resultado y la aplicación compara la mejor distancia contra el umbral configurado de 0.85. Si la mejor distancia es mayor que este valor, el sistema responde que no existe evidencia suficiente en los documentos y establece `abstained = true`.

En las pruebas realizadas, las preguntas dentro del corpus produjeron mejores distancias aproximadamente entre 0.5385 y 0.6217, mientras que las preguntas fuera del corpus probadas produjeron valores entre 0.9780 y 0.9907. «What is supervised learning?» obtuvo aproximadamente 0.6217 y generó una respuesta con citas; «What is the current stock price of NVIDIA?» obtuvo aproximadamente 0.9780 y activó la abstención. El umbral fue seleccionado empíricamente para este corpus y configuración y no representa un valor universal.

Tecnologías y funciones

Tecnología	Funciones
Python	Lenguaje principal de desarrollo
FastAPI	API REST del backend
Streamlit	Interfaz de usuario
ChromaDB	Base vectorial persistente y recuperación por similitud
gemini-embedding-001	Embeddings de documentos y consultas
gemini-3.6-flash	Generación de respuestas fundamentadas
PyPDF	Extracción de texto de PDF
Python-dotenv	Gestión de variables de entorno

La API expone *GET /health*, *POST /ingest* y *POST /query*. La interfaz muestra la respuesta, citas, páginas, distancias de recuperación y el estado de abstención cuando corresponde.

Evidencias de ejecución:

La ejecución del programa se muestra en el siguiente video:

<https://youtu.be/JVkdUTMHuVY>